基于朴素贝叶斯和预训练Bert模型的中文句子情感分类实践

1.任务介绍

本次实践选题为AI研习社2019年9月份举办的中文对话情感分析任务，并在原任务基础上进行了拓展。任务首先给定一中文语句数据集，每个句子均有情绪标注，要求建模并预测测试集中每一句话的情绪。原任务为二分类问题，本次实践采用的数据集为知识发现与数据挖掘课程中所提供的中文语句数据集，其中每句话的情绪可分为6类:Happiness, Love, Sorrow, Fear, Disgust, None，分别用数字标签1-6代替。本次实践先采用了传统的朴素贝叶斯方法建模并预测，之后使用预训练的Bert模型进行了建模预测,并在最后对比了两种模型的效果差异。

2.数据集介绍

本次实践采用研究生知识发现与数据挖掘课程所提供的中文语句数据集，训练集中共包含36810句中文语句，测试集共包含1000句中文语句，其中训练集中各情绪标签对应的语句数如表所示：

标签	语句数
1	5648
2	6512
3	2534
4	432
5	4138
6	17546

数据集中的句子及标签格式示例如下：

ID	Text	Labels
1	我就奇怪了??为啥你能拍得这么美呢 _eou_ 因为我做什么都认真，都诚心诚意！ _eou_ 好你诚心诚意！我谦虚低调！咱都是优秀品格的人再赞一个??干杯 _e	2222
2	是这是人家自己的事就算我能见到她也不会说你们分手吧什么的可是我真心不喜欢冯绍峰这个理由够吗 _eou_ 最起码那孩子对倪妮没恶意，你不开心也别来这	5555
3	狂上加狂的旧时燕飞帝王家和危宫惊梦 _eou_ 哈哈，我也推这本。她古文好厉害 _eou_ 原来特别喜欢他写的耽美，没想到男女的也写的很好看，太棒了哈 _	6222
4	呵呵呵呵呵呵呵你拍我家枇杷树跟我说了嘛！！！不准吃我家枇杷！！！都我的！！！ _eou_ 写你名了？写你名了？写你名了？ _eou_ 你难道没看到么，	5555
5	哎，我就吃下这个哑巴亏算了 _eou_ 呔，妖怪，死到临头还嘴硬 _eou_ 真不愧是嘴脸红，看我不收了你 _eou_ 自古真情留不住，唯有套路留人心 _eou_ 逭	35536
6	偶看报纸上的评论,好像也不看好. _eou_ 明天要是有时候间就去看少年派据说很好，周末快乐哦 _eou_ 周末快乐!等你看完再讲评讲评哦 _eou_ 下午看了少年	3222
7	你这个包裹厉害的！据说最近除重量外，要算体积了。 _eou_ 我刚好是在那个通知发出的前一天发货的 _eou_ 太棒了！我的几件东西还没到齐，还得等几天	26266
8	道理是这样的，不过茶没味了，也是有过程的。有些茶是会让人回味无穷的 _eou_ 茶本身不会回味无穷，能够回味无穷的都是自己内心的感受。 _eou_ 其实，	6622
9	我当时也是这样想的～实在是太美了～ _eou_ 是咯，不过我还是好想换相机喔哈哈 _eou_ 要换单反么？？不过我最近才刚买了新的 _eou_ 亲爱的你买的啥？	21666
10	样子问题！我早就说了不卖！哈哈 _eou_ 要你管啦，票房又不能说明一切，不过有些人不懂欣赏罢了。 _eou_ 啊哈哈，叔叔莫着急，你喜欢周杰伦必须得爱，	152636
11	饿，我这边好塞车。 _eou_ 你唔系搭地铁啜咩？ _eou_ 地铁？要专线，好远。 _eou_ 呃~虽然我中意坐巴士多过坐地铁~哈哈~不过地铁快喔~	3632
12	这什么地方这么落后啊… _eou_ 居然是广州的一个铺位 _eou_ 你没给他普及微信支付么…看来还要加大力度啊，看来这老板平时不玩微信啊！ _eou_ 要好好	3331
13	pgone陌陌号上发dp照片配字：约吗 _eou_ 还在626国际禁毒日那天发的…屁股王很牛逼是吗？ _eou_ 对呀光明正大抄袭又光明正大约d王昊怕过谁 _eou_ 原	5555
14	拒绝就不会吃了 _eou_ 你这逻辑有问题，好好读书吧 _eou_ 呵呵哒，难道你是来这里展现自己的高风亮节的？ _eou_ 难道你来这里展现你的无知愚昧？	6555
15	你们为什么见到雪那么兴奋 _eou_ 我从小到大没有见过雪。你觉得呢。跟你们喜欢大海一样 _eou_ 我本人对大海没什么感觉hhhh第一次看见也不兴奋 _eou_	6161
16	所以在盼望结束么 _eou_ 是期待奖品的那天嘻嘻 _eou_ 那要是抽不到你你不得哭 _eou_ 抽不到口红我可能会哭	6163
17	最好吃的是什么？不是季节啊，我首先想到的就是大闸蟹。 _eou_ 那边没有最好吃的！不好吃都 _eou_ 坐高铁去得？几个小时多钱？我考虑要是去上海可以:	63116
18	我想知道有没有好心人点进我的相册看看我是几分的…（小声逼逼&瑟瑟发抖） _eou_ 8分呀6条条条符合呀 _eou_ 真爱宝宝怎么在这被你捞出来的 _eou_ 哈	4221
19	摸摸头，坚强的小土豆！ _eou_ 噗你也是大家都一样作为特别关注我特别荣幸噗 _eou_ 哈哈哈，我还指望着你成了网红一起卖面膜呢 _eou_ 噗好哒那我要	2111
20	铁定是没成功啊 _eou_ 哎呀?你觉得可能吗！我一出马不成功不可能！ _eou_ 哦哟，是不是哦，出马和看看 _eou_ 哈哈哈哈！开玩笑的！人家一定要谦虚啦	32511

3.实践过程

3.1 朴素贝叶斯模型

3.1.1 模型介绍

朴素贝叶斯是分类任务中常用的机器学习模型，它首先基于特征条件独立假设学习输入输出的联合概率分布，然后基于此策略对给定的输入x，利用贝叶斯定理求出后验概率最大的输出y。

本次任务中传统分类模型主要通过Python中sklearn库的朴素贝叶斯方法实现。sklearn库中封装了三个朴素贝叶斯的分类算法类，分别是：GaussianNB,MultinomialNB和BernoulliNB，其中，GaussianNB适用于样本特征分布为连续值的场景；MultinomialNB适用于样本特征为多元离散值的场景；BernoulliNB适用于样本特征是二元离散值或者很稀疏的多元离散值。本次任务要实现对不同的句子进行分类，故为离散值，使用类为MultinomialNB。

3.1.2 数据预处理

本部分数据预处理过程主要实现两个流程，第一部分是对数据集中的句子进行分词处理。由于中文与英文的格式不同，对于英文处理可以直接使用空格取词后建立词典，而在处理中文数据时需要进行分词。本次实践分词使用Python中的常用的方法jieba库进行分词。

第二部分是采用目前NLP领域常用的提高分类准确率的方法即停用词处理，使用stopwords文件去掉如嗯、啊等对分类结果无明显作用的词语，本次实践采用的stopwords文件为哈工大公开的停用词表。（川大停用词库,哈工大停用词表,百度停用词表百度网盘提取码4sm6）

经过两步处理后可以得到分词后的句子作为模型的输入数据，代码如下：

```
#创建停用词表
def stopwordslist():
    stopwords = [line.strip() for line in open('newstopwords.txt',encoding='UTF-
8').readlines()]
    return stopwords

#对每一行进行中文分词

def seg_depart(sentence):
    # 对文档中的每一行进行中文分词
    # print("正在分词")
    sentence_depart = jieba.cut(sentence.strip())
    # 创建一个停用词列表
    stopwords = stopwordslist()
    # 输出结果为outstr
    outstr = ''
    # 去停用词
    for word in sentence_depart:
        if word not in stopwords:
            if word != '\t':
                outstr += word
                outstr += " "
    return outstr
```

3.1.3 模型建立与训练

朴素贝叶斯模型的建立与训练较为简单，不需要设置较为复杂的参数。首先，对所有输入句子的单词进行统计，建立词典allwords，并利用词典将中文句子数据转为词向量数据vector，之后将数据输入到MultinomialNB模型中进行训练即可。

建模训练实践环境：CPU:Intel(R) Core(TM) i7-8750H CPU @ 2.20GHz　2.20 GHz；GPU:Nvidia

Geforce GTX 1050ti

由于本机实践环境限制，传统模型训练仅采用了10000条句子数据进行训练并进行了测试。代码如下：

```
labels = array(labels)
allwords = set()
print("开始统计")
for sen in articles:
    for word in sen:
        allwords.add(word)
allwords = list(allwords)
print("完成！！！！")
test = pd.read_csv('test_last.csv',encoding='UTF-8')
test = test.values.tolist()
# del test[4000:]
print(test[0:10])
results = list()
vector = list()
for sen in articles:
    temp = list(map(lambda x:sen.count(x),allwords))
    vector.append(temp)

model = MultinomialNB()
# model.cuda()
model.fit(vector,labels)
```

3.1.4 模型测试

模型测试主要通过model.predict()方法实现，将数据输入模型后统计输出结果并将预测标签结果输出到文件中进行保存。代码如下：

```
def Predict(string):
    words = string.split(' ')
    currentVector = array(tuple(map(lambda x:words.count(x),allwords)))
    # currentVector.cuda()
    result = model.predict(currentVector.reshape(1,-1))
    return result
for i in test:
    result = Predict(i[0])
    results.append(result)
print(results[0:10])
test =pd.DataFrame(data = results)
test.to_csv('chuantong_result.csv',encoding='UTF-8',index=None,header=None)

result_index = 1
result_test = []
for label in results:
    x = {}
    x['ID'] = result_index
    x['Last Label'] = int(label)
    result_test.append(x)
    result_index += 1
with open("chuantong_result_last.csv",'w',newline='',encoding='UTF-8') as f_csv:
    writer = csv.writer(f_csv)
```

```
    writer.writerow(['ID','Last Label'])
    for n in result_test:
        writer.writerow(n.values())
```

3.2 预训练Bert模型

3.2.1 模型介绍

Bert模型是Google于2018年10月发布的自然语言处理模型，利用transformer的注意力机制，能实现很强大的自然语言处理应用。本次实践主要利用Python中transformers库的BertModel类实现，配合Pythorch进行模型的训练评估。

实践环境：CPU:Intel(R) Xeon(R) Gold 5215 CPU @ 2.50GHz；GPU：NVIDIA TESLA T4 16GB *2

3.2.2 模型建立与训练

本部分数据预处理的过程与上文类似，获取输入数据后进行模型的构建，引入Bert模型，在最顶层加入分类功能，实现自定义的目的。因为功能简单线性，模型构建使用Pytorch的标准线性写法，Bert返回的是768维的张量。代码如下：

```
#模型构建
import torch.nn as nn


class MyBert(nn.Module):

    def __init__(self):
        super().__init__()
        self.bert = BertModel.from_pretrained("bert-base-chinese",
return_dict=False)
        self.drop_out = nn.Dropout(0.1)
        self.dense = nn.Linear(768, 6)
        torch.nn.init.normal_(self.dense.weight, std=0.02)

    def forward(self, ids, mask, token_type_ids):
        _, out = self.bert(
            ids,
            attention_mask=mask,
            token_type_ids=token_type_ids
        )
        out = self.drop_out(out)
        logits = self.dense(out)
        return logits
```

完成模型的构建之后需要对输入的数据进行处理，使其能够输入到模型中进行计算。首先是配套使用transformer里的BertTokenizer分词方式对数据进行处理，然后输出的时候再转换成pytorch中的tensor格式。同时为了保证所有输入shape一致，需要对原始数据进行分类，即字符长度大于MAX_LEN和小于等于两种形式的处理，并进行padding处理。代码如下：

```
def process_data(tweet, sentiment, tokenizer, max_len):
    tok_tweet = tokenizer(tweet)
    input_ids_orig = tok_tweet.input_ids[1:-1]
    input_ids = [101] + input_ids_orig + [102]
```

```
    token_type_ids = tok_tweet['token_type_ids']
    attention_mask = tok_tweet['attention_mask']

    padding_length = max_len - len(input_ids)
    if padding_length > 0:
        input_ids = input_ids + ([0] * padding_length)
        attention_mask = attention_mask + ([0] * padding_length)
        token_type_ids = token_type_ids + ([0] * padding_length)
    elif padding_length <= 0:  # 截断
        input_ids = [101] + input_ids_orig[:max_len - 2] + [102]
        attention_mask = attention_mask[:max_len]
        token_type_ids = token_type_ids[:max_len]

    return {  # 这里返回的是list格式的tensor
        'ids': input_ids,
        'mask': attention_mask,
        'token_type_ids': token_type_ids,
        'orig_tweet': tweet,
        'sentiment': sentiment,
    }
```

数据处理完成后开始构建训练函数并设置为每120批次返回一次训练结果，使用的优化器为在NLP领域表现比较好的AdamW优化器，部分代码如下：

```
def train_fn(data_loader, model, optimizer, device, scheduler=None):
    model.train()
    tk0 = tqdm(data_loader, total=len(data_loader))

    for bi, d in enumerate(tk0):
        #         print(d)
        ids = d["ids"]
        token_type_ids = d["token_type_ids"]
        mask = d["mask"]
        sentiment = d["sentiment"]
        orig_tweet = d["orig_tweet"]

        sentiment = sentiment.to(device)
        ids = ids.to(device, dtype=torch.long)
        token_type_ids = token_type_ids.to(device, dtype=torch.long)
        mask = mask.to(device, dtype=torch.long)
        model.zero_grad()

        outputs = model(
            ids=ids,
            mask=mask,
            token_type_ids=token_type_ids,
        )
        #         loss = loss_fn(outputs_start, outputs_end, targets_start,
targets_end)
        loss = loss_func(outputs, sentiment)
        loss.backward()
        optimizer.step()
        scheduler.step()

        outputs = torch.softmax(outputs, dim=1).cpu().detach().numpy()
```

```
        if bi % 120 == 0:
            print('Step:', bi)
            print('train loss: %.4f' % loss.item())
            print('outputs:', outputs)
            pred_y = torch.max(torch.tensor(outputs, dtype=torch.float), dim=1)
[1].data.numpy()
            print('pred_y:', pred_y)
            accuracy = (sum(pred_y == np.array(sentiment.data.cpu())).item()) /
sentiment.size(0)
            print('train accurancy: %.2f' % accuracy)
```

训练过程中的参数设置如下，本次训练的EPOCHS共设置了3，4，6，8四组，MAX_LEN共设置了64，128，256和512维四组。

```
TRAIN_BATCH_SIZE = 32
TEST_BATCH_SIZE = 16
VALID_BATCH_SIZE = 8
EPOCHS = 4
MAX_LEN = 128
```

训练完成后将模型保存，便于后续的加载测试。代如下：

```
# 模型保存
torch.save({'state_dict': model.state_dict()},
'bert_chinese_simple_4epoch_dict.pth.bar') #只保留参数
```

3.2.3 模型测试

测试集的数据处理与训练集类似，获取测试数据后首先需要加载之前训练后保存的模型，之后利用模型进行预测分类。代码如下：

```
def test_fn(data_loader, model):
    final_output = []
    with torch.no_grad():
        tk0 = tqdm(data_loader, total=len(data_loader))

        for bi, d in enumerate(tk0):
            ids = d["ids"]
            token_type_ids = d["token_type_ids"]
            mask = d["mask"]
            orig_tweet = d["orig_tweet"]

            ids = ids.to(device, dtype=torch.long)
            token_type_ids = token_type_ids.to(device, dtype=torch.long)
            mask = mask.to(device, dtype=torch.long)

            outputs = model(
                ids=ids,
                mask=mask,
                token_type_ids=token_type_ids,
            )
```

```
            outputs_res = torch.softmax(outputs, dim=1).cpu().detach().numpy()

            for px, tweet in enumerate(orig_tweet):
                res_sentiment = np.argmax(outputs_res[px])
                final_output.append(res_sentiment)
    return final_output
```

4.实践结果

4.1 评价指标

本次实践评价采用东北大学数据挖掘课题组机器学习测评系统进行结果评估，共包含三项指标，分别为accuracy、recall和macro-F1值。

4.2 结果展示

4.2.1 朴素贝叶斯模型评估结果

朴素贝叶斯模型的结果评估如图所示：

4.2.2 Bert预训练模型评估结果

Bert预训练模型3个Epoch，128维测试结果：

Bert预训练模型4个Epoch，128维测试结果：

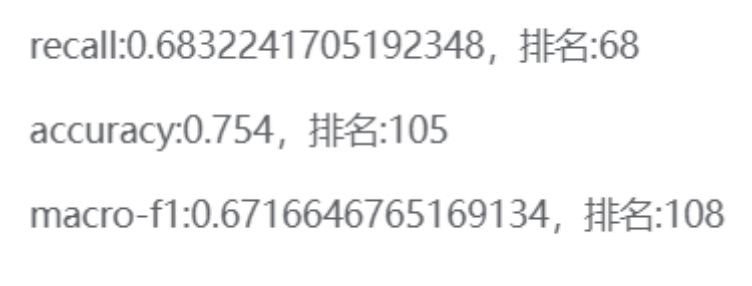

Bert预训练模型8个Epoch，128维测试结果：

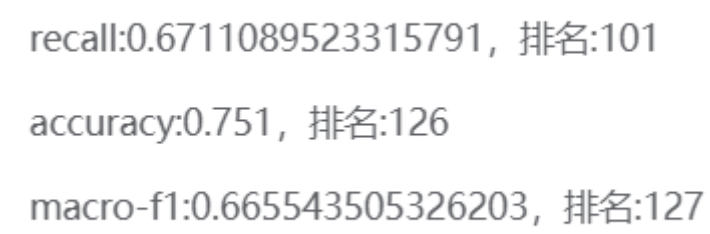

Bert预训练模型6个Epoch，64维测试结果：

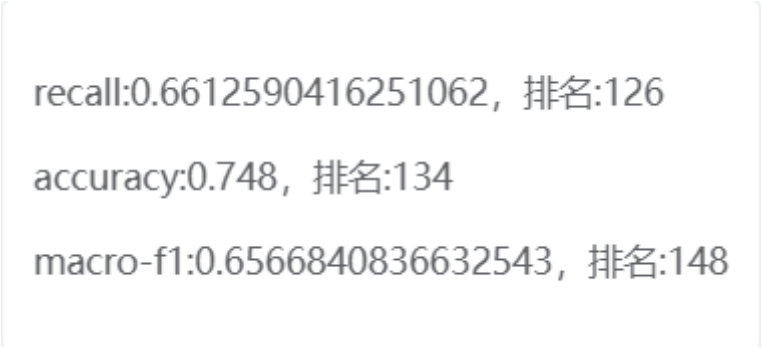

Bert预训练模型6个Epoch，256维测试结果：

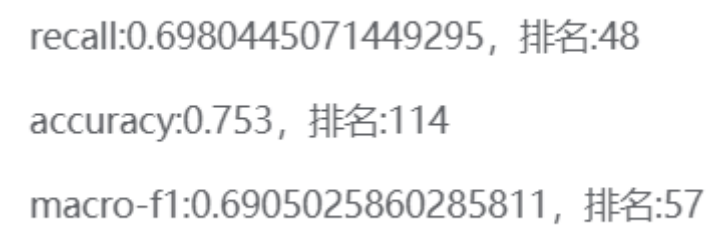

Bert预训练模型6个Epoch，512维测试结果：

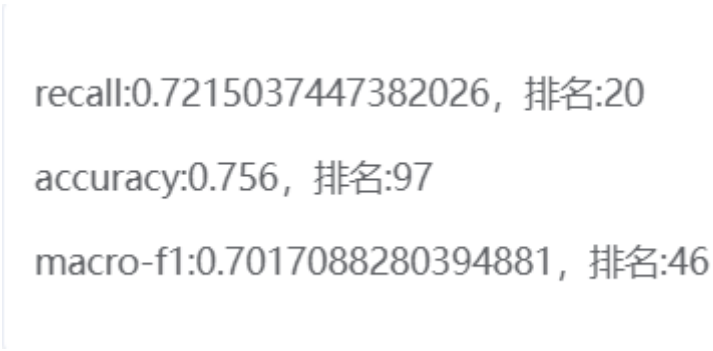

4.2.3 实践结果分析

通过对比本次实践结果，能够发现，基于Bert预训练模型的方法总体效果要远远优于传统的机器学习朴素贝叶斯方法，而对于基于Bert预训练模型的方法，通过调整参数能够进一步提高模型性能。

5.实践总结

经过本次实践，我了解了更多自然语言处理方面的知识和技能，同时对于自然语言处理中常见的分词、embedding操作等更加熟悉，能够在实践中利用课上学到的知识解决问题。除此之外，此次实践最大的收获是熟练掌握了关于服务器模型训练方面的操作，自主完成了服务器虚拟环境配置，并学会利用服务器进行多卡训练模型，利用git、xftp等工具实现本地、服务器和仓库的同步。

总之，通过本次实践，我收获很多，在未来的学习生活中还需要继续锻炼，熟练各项操作，争取做得更好！

相关参考

BERT模型详解

自然语言处理三大模型介绍

Bert模型（Pytorch）中文段落情感判断